

# Redes neuronales avanzadas: convolucionales

Diplomatura en Ciencia de Datos, Aprendizaje  
Automático y sus Aplicaciones



# 1. Intuición en imágenes



# Recursos

[Curso Stanford](#)

[Tutorial towardsdatascience.com](https://towardsdatascience.com)

Filminas originales: [Jorge Sánchez](#), inspiradas en [A. Vedaldi - cs231n \(Stanford\)](#)




# Imágenes = 2D

Las imágenes tienen propiedades espaciales:

- En orden de los datos es en dos (o tres) dimensiones
- Los mismos patrones se repiten en distintas posiciones: bordes, esquinas


# Multilayer perceptron

32x32x3 image -> stretch to 3072 x 1



# Convolución

Tenemos que procesar una entrada 2D o 3D



# Convolución

0	0	0	0	0	0
0	105	102	100	97	96
0	103	99	103	101	102
0	101	98	104	102	100
0	99	101	106	104	99
0	104	104	104	100	98

Image Matrix

Kernel Matrix

0	-1	0
-1	5	-1
0	-1	0

320				

Output Matrix

$$\begin{aligned} & 0 * 0 + 0 * -1 + 0 * 0 \\ & + 0 * -1 + 105 * 5 + 102 * -1 \\ & + 0 * 0 + 103 * -1 + 99 * 0 = 320 \end{aligned}$$

**Convolution with horizontal and  
vertical strides = 1**



# Convolución

La convolución es la combinación de dos matrices (funciones):

- La imagen original
- El filtro de la convolución

El resultado es otra matriz (función)



# Filtro de convolución

Los filtros capturan distintos aspectos de una imagen: detección de bordes, desenfoque, [más ejemplos](#)



# Filtro de convolución

0	0	0	0	0	0	0
0	1	1	0	0	1	0
0	1	0	0	1	1	0
0	0	0	1	1	1	0
0	1	0	0	1	1	0
0	1	1	0	0	1	0
0	0	0	0	0	0	0

-1	-1	-1
-1	8	-1
-1	-1	-1

6				

# Filtro de convolución

0	0	0	0	0	0	0
0	1	1	0	0	1	0
0	1	0	0	1	1	0
0	0	0	1	1	1	0
0	1	0	0	1	1	0
0	1	1	0	0	1	0
0	0	0	0	0	0	0

-1	-1	-1
-1	8	-1
-1	-1	-1

6	6			

# Filtro de convolución

0	0	0	0	0	0	0
0	1	1	0	0	1	0
0	1	0	0	1	1	0
0	0	0	1	1	1	0
0	1	0	0	1	1	0
0	1	1	0	0	1	0
0	0	0	0	0	0	0

-1	-1	-1
-1	8	-1
-1	-1	-1

6	6	-2		

# Filtro de convolución

0	0	0	0	0	0	0
0	1	1	0	0	1	0
0	1	0	0	1	1	0
0	0	0	1	1	1	0
0	1	0	0	1	1	0
0	1	1	0	0	1	0
0	0	0	0	0	0	0

-1	-1	-1
-1	8	-1
-1	-1	-1

6	6	-2	-3	6
6	-4	-4	3	4
-2	-3	5	2	3
6	-4	-4	3	4
6	6	-2	-3	6

# Filtro de convolución


0	0	0	0	0	0	0
0	1	1	0	0	1	0
0	1	0	0	1	1	0
0	0	0	1	1	1	0
0	1	0	0	1	1	0
0	1	1	0	0	1	0
0	0	0	0	0	0	0

-1	-1	-1
-1	8	-1
-1	-1	-1

6	6	-2	-3	6
6	-4	-4	3	4
-2	-3	5	2	3
6	-4	-4	3	4
6	6	-2	-3	6

[Para jugar un rato](#)

## 2. CNN



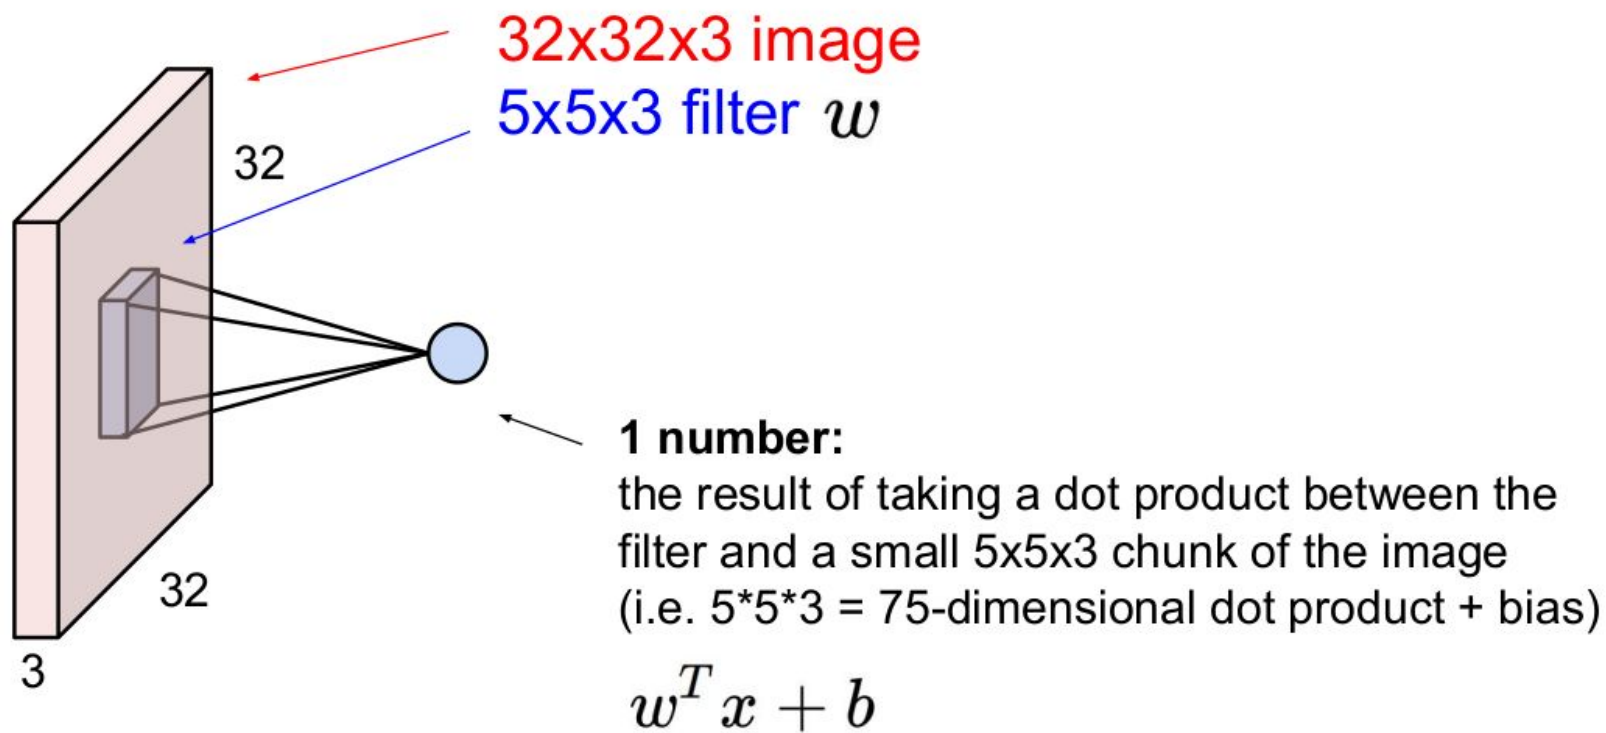
*Los filtros pueden ser vistos como  
extractores de información.*

*Las redes convolucionales APRENDEN  
numerosos filtros (feature extractors)*






# Convolution Layer




# Convolution Layer




# Convolution Layer

consider a second, **green** filter




For example, if we had 6 5x5 filters, we'll get 6 separate activation maps:



We stack these up to get a “new image” of size 28x28x6!

## Multiple layers

**Convolution, activation, convolution, activation, ...**




A deep convolutional neural networks chains several filtering & non-linear activation function sequences.

The non-linear activation functions are essential. Why?


# Pooling

El pooling es un mecanismo para reducir la dimensionalidad de las capas.



# Case Study: LeNet-5

[LeCun et al., 1998]



Conv filters were 5x5, applied at stride 1



Subsampling (Pooling) layers were 2x2 applied at stride 2

i.e. architecture is [CONV-POOL-CONV-POOL-CONV-FC]



# Stride

El stride controla la distancia entre la aplicación de los filtros, y el tamaño del output

Stride 1




Stride 3





# Padding

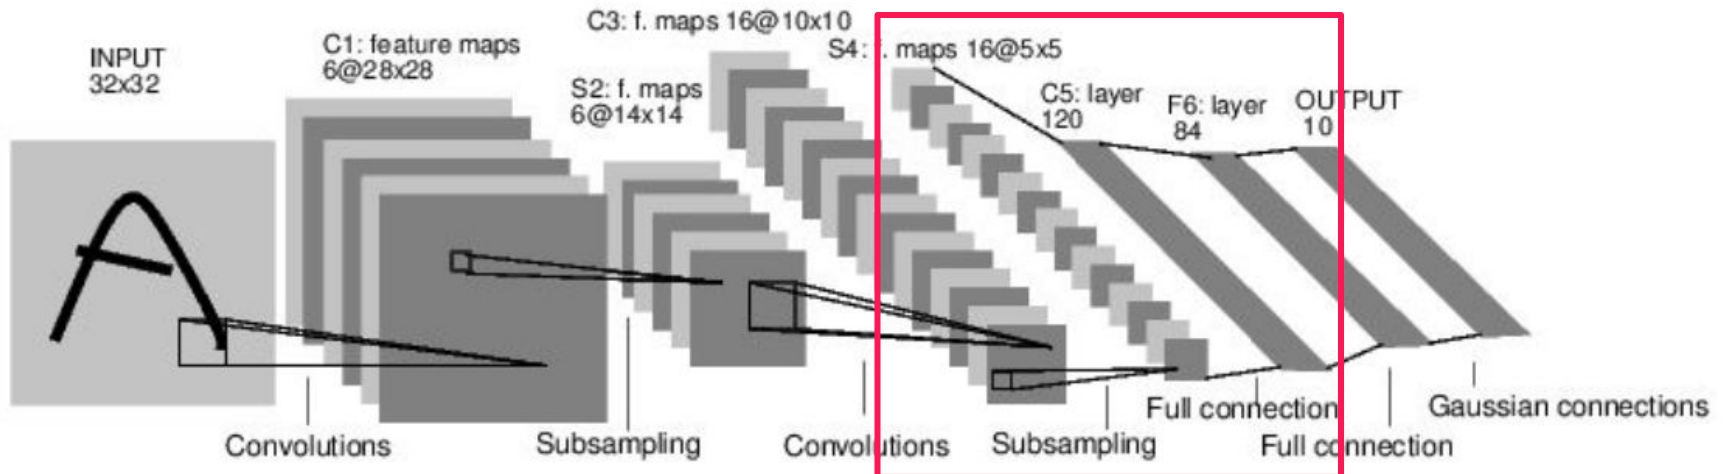
Padding 2



El padding permite la aplicación de los filtros a los elementos del borde de la imagen, y afecta el tamaño del output

# Flatten


Para poder aplicar la capa de clasificación, tenemos que convertir la salida de la convolución a 1D



### 3. Práctico con notebook




## 4. CNNs para texto?



# Convolución 1D

Aplicamos la convolución a cada palabra ([Conv1D](#))





# References

- + Chris Piech, et al. 2015. *Deep Knowledge Tracing*. In Proceedings of the 28th International Conference on Neural Information Processing Systems (NIPS'15)
  - + Siddharth Reddy, Igor Labutov, and Thorsten Joachims. 2016. *Learning Student and Content Embeddings for Personalized Lesson Sequence Recommendation*. In Proceedings of the Third (2016) ACM Conference on Learning @ Scale (L@S '16).
- 